

# LLM-Serving-Service

## Leistungsbeschreibung & zusätzliche Bedingungen

von T-Systems International GmbH

Version: 1.25

Date: 30. 10. 2026

T Systems

Let's power higher performance

# Impressum

**Herausgeber**

**T-Systems International GmbH**

**Friedrich-Ebert-Allee 140**

**53113 Bonn**

**Deutschland**

**WEEE-Reg.-Nr. DE50335567**

**nachfolgend – Telekom - genannt**

Die gesetzlichen Pflichtangaben finden Sie unter: www.t-systems.de/pflichtangaben |

Copyright © 2024 Alle Rechte, auch die des auszugweisen Nachdruckes, der elektronischen oder fotomechanischen Kopie sowie die Auswertung mittels Verfahren der elektronischen Datenverarbeitung, vorbehalten.

Internal PIMS-ID: 34011758/1096

Confidentially Class: Public

# Inhaltsverzeichnis


**1 Einleitung ..... 4**

**2 Funktionen ..... 4**

2.1 LLM-Self-Service Portal ..... 4

2.2 API ..... 4

2.3 Verfügbare LLMs und Embedding-Modelle ..... 4

2.3.1 LLMs und Embedding-Modelle mit Datenverarbeitung innerhalb EU/EWR und Staaten mit Angemessenheitsbeschluss ..... 5

2.3.2 LLMs und Embedding-Modelle mit Datenverarbeitung außerhalb EU/EWR und Staaten ohne Angemessenheitsbeschluss ..... 6

2.3.3 Testmodelle ..... 7

**3 Leistungen der Telekom ..... 8**

3.1 Bereitstellung ..... 8

3.2 Betrieb ..... 8

3.2.1 Kundensupport ..... 8

3.2.2 Leistungsübergabepunkt ..... 9

3.2.3 Service Quality ..... 9

3.2.4 Wartungsarbeiten ..... 10

3.2.5 Reporting ..... 10

3.3 Nutzungsbedingungen, Lizenzbestimmungen ..... 11

3.3.1 Einhaltung der KI-Verordnung ..... 11

3.3.2 Allgemeine Nutzungsbedingungen ..... 11

3.3.3 Lizenzen, Nutzungsbedingungen und Datenschutzbestimmungen ..... 12

3.3.4 Medical Device Regulation (MDR) ..... 14

3.3.5 Hochrisiko-KI-Systeme, Verbotene Anwendungsfälle ..... 14

3.3.6 Haftung, Freistellung, Kündigung ..... 14

3.3.7 Feedback ..... 14

3.4 Optionale Leistungen ..... 15

3.4.1 LLMs auf dedizierter Instanz ..... 15

3.4.2 Feintuning von Modellen ..... 15

3.4.3 Installation auf einer kundeneigenen Umgebung ..... 15

3.4.4 Zusätzliche LLMs und Embedding Modelle ..... 15

3.4.5 Weitere Unterstützungsleistungen ..... 15

**4 Leistungsänderungen durch Telekom ..... 16**

**5 Mitwirkungsleistungen des Kunden ..... 16**
5.1 Allgemeine Mitwirkungsleistungen ..... 16
5.2 Mitwirkungsleistungen bei Betrieb ..... 17
**6 Mindestlaufzeit/Beendigung ..... 18**
**7 Preise, Kommerzielle Bedingungen ..... 18**
7.1 Verfahren der Entgeltberechnung ..... 18
7.2 Preise ..... 19
7.2.1 Tarif Essential ..... 19
7.2.2 Tarif Professional ..... 21
7.2.3 Tarif Agentic ..... 23
7.2.4 Preise für optionale Dienstleistungen ..... 24
**8 Glossar/ Abkürzungsverzeichnis ..... 25**

# 1 Einleitung

Mit dem LLM-Serving-Service stellt die Telekom dem Kunden einen Zugang zu verschiedenen Large Language Modellen (LLM) und Embedding-Modellen as-a-Service zur Nutzung im Self-Service bereit. Der Zugang zu den LLMs und Embedding-Modellen wird über eine API mittels eines API-Keys bereitgestellt. Mit diesem hat der Kunde die Möglichkeit, die LLMs über ein Chat-Frontend zu nutzen.

# 2 Funktionen

## 2.1 LLM-Self-Service Portal

Das Self-Service Portal ist durch den Kunden über das Internet unter https://apikey.llmhub.t-systems.net erreichbar und bietet diesem folgende Funktionen zur Nutzung im Self-Service:

a. Übersicht der verfügbaren API-Keys und der mit den Keys verbundenen Modellen.
b. Generierung und Verwaltung von API-Keys für den Zugang zu den Modellen.
c. Übersicht des Token-Verbrauchs je Key und Modell.

Die Telekom stellt dem Kunden-Administrator Log-In-Daten für das LLM-Self-Service Portal bereit. Der Kunden-Administrator kann für das Portal weitere Nutzer anlegen, die sich dort im Self-Service einen oder mehrere API-Keys generieren können. Die generierten API-Keys ermöglichen den Zugriff auf die Modelle des vereinbarten Tarifs.

## 2.2 API

Der Kunde kann die ausgewählten LLMs und Embedding-Modelle über eine standardisierte API ansteuern. Dies ist via HTTPS-Request oder mit Hilfe des Python Pakets „openai“ möglich. Die Telekom stellt dem Kunden eine aktuelle Dokumentation unter https://docs.llmhub.t-systems.net/category/model-serving zur Verfügung.

## 2.3 Verfügbare LLMs und Embedding-Modelle

Der LLM-Serving-Service unterliegt einer ständigen Weiterentwicklung. Die verfügbaren LLMs und Embedding-Modelle können sich daher von Zeit zu Zeit ändern, Modelle können von der Telekom hinzugefügt und entfernt werden.

Der LLM-Serving-Service stellt 2 Gruppen von LLMs und Embedding Modellen bereit:

- LLMs und Embedding-Modelle, bei denen die Datenverarbeitung nur innerhalb EU/EWR und in Staaten mit einem datenschutzrechtlichen Angemessenheitsbeschluss der EU-Kommission stattfindet.

- LLMs und Embedding-Modelle, bei denen die Datenverarbeitung auch außerhalb der EU/EWR und/oder in Staaten ohne datenschutzrechtlichen Angemessenheitsbeschluss der EU-Kommission stattfindet.

Die Telekom weist ausdrücklich darauf hin, dass es aufgrund gesetzlicher Bestimmungen (wie bspw. im Bereich der Verarbeitung von Sozialdaten und/oder Gesundheitsdaten) unzulässig ist, bestimmte Datenkategorien außerhalb der EU/EWR und in Ländern ohne datenschutzrechtlichen Angemessenheitsbeschluss der EU-Kommission zu verarbeiten. Bei dieser Betrachtung sind auch die Unterauftragnehmer jeden Grades über die Verarbeitungskette in die rechtliche Bewertung mit einzubeziehen (z.B. § 80 Abs. 2 SGB X, § 393 Abs. 2 SGB V).

Die Telekom weist ferner darauf hin, dass die rechtliche Bewertung der Zulässigkeit der Nutzung einer der in dieser Leistungsbeschreibung beschriebenen LLMs und Embedding-Modelle allein in den Verantwortungsbereich des Kunden fällt und die Telekom die Zulässigkeit der Nutzung der ausgewählten LLMs und Embedding-Modelle durch den Kunden nicht überprüfen kann und wird.

Aus diesem Grunde sichert der Kunde der Telekom zu, dass er die Zulässigkeit der Nutzung der ausgewählten LLMs und Embedding-Modelle geprüft hat und hierfür die alleinige Verantwortlichkeit trägt. Ansprüche, die aus einer rechtswidrigen Nutzung der LLMs und Embedding-Modelle resultieren, sind vom Kunden allein zu tragen und berechtigen nicht zu Haftungsansprüchen, Regressforderungen und der Ausübung vertraglicher Gestaltungsrechte gegenüber der Telekom. Der Kunde stellt die Telekom von allen Ansprüchen von Betroffenen und Dritten (insb. Aufsichtsbehörden) - auf erstes Anfordern - vollumfänglich frei und erstattet der Telekom die Kosten der notwendigen Rechtsverteidigung, soweit diese auf einer rechtswidrigen Nutzung der Leistung beruhen. Weitergehende Schadenersatzansprüche infolge gesetzeswidriger Nutzung bleiben unberührt.

### 2.3.1 LLMs und Embedding-Modelle mit Datenverarbeitung innerhalb EU/EWR und Staaten mit Angemessenheitsbeschluss

Die LLMs und Embedding-Modelle dieser Kategorie werden von der Telekom betrieben. Die Verarbeitung der Daten und die Leistungserbringung erfolgt innerhalb der EU/EWR und/oder in Staaten mit datenschutzrechtlichem Angemessenheitsbeschluss der EU-Kommission.

Ihre Anfragen und die darauf erhaltenen Antworten werden im LLM Serving Service standardmäßig nicht dauerhaft gespeichert und auch nicht dazu verwendet, die Sprachmodelle zu trainieren. Damit der Service schneller antwortet, gibt es eine sogenannte Cache-Funktion: Dabei werden bereits verarbeitete Anfragen für eine begrenzte Zeit zwischengespeichert, sodass ähnliche oder wiederkehrende Anfragen schneller beantwortet werden können. Diese Funktion ist standardmäßig eingeschaltet, kann von Kunden aber jederzeit ein- oder ausgeschaltet werden.

Weitere Informationen zu den Cache-Einstellungen: https://docs.llmhub.t-systems.net/guides/prefix-caching/

Aktuell sind folgende Modelle verfügbar:

| Modell | Modell-typ | Plattform |
|---|---|---|
| **Gemma 4 31B** | LLM | T-Cloud Public / Industrial AI Cloud |
| **Mistral AI Mistral Small 4** | LLM | T-Cloud Public / Industrial AI Cloud |
| **Qwen3.6 35B** | LLM | T-Cloud Public |
| **Qwen 3.8 27B** | LLM | T-Cloud Public / Industrial AI Cloud |
| **NVIDIA Nemotron 3 Super** | LLM | T-Cloud Public / Industrial AI Cloud |
| **GLM 5.3** | LLM | T-Cloud Public / Industrial AI Cloud |
| **GLM 5.3 Flash** | LLM | T-Cloud Public / Industrial AI Cloud |
| **OpenAI GPT-OSS-120B** | LLM | T-Cloud Public / Industrial AI Cloud |
| **Jina AI jina-embeddings-v2-base-de** | Embedding | T-Cloud Public |
| **BAAI text-embedding-bge-m3** | Embedding | T-Cloud Public |
| **Qwen3-Embedding-8B** | Embedding | T-Cloud Public / Industrial AI Cloud |
| **Qwen3-Reranker-4B** | Reranker | T-Cloud Public / Industrial AI Cloud |
| **LightOnOCR-3-4B** | OCR | T-Cloud Public / Industrial AI Cloud |
| **PaddleOCR-VL-1.6** | OCR | T-Cloud Public / Industrial AI Cloud |
| **OpenAI Whisper Large v3** | STT | T-Cloud Public |
| **OpenAI Whisper Large v3 Turbo** | STT | T-Cloud Public |

### 2.3.2 LLMs und Embedding-Modelle mit Datenverarbeitung außerhalb EU/EWR und Staaten ohne Angemessenheitsbeschluss

Die LLMs und Embedding-Modelle dieser Kategorie werden nicht von der Telekom betrieben. Die Verarbeitung der Daten und die Leistungserbringung kann außerhalb der EU/EWR und/oder in Staaten ohne datenschutzrechtlichem Angemessenheitsbeschluss der EU-Kommission erfolgen.

Anfragen an LLMs und Embedding Modelle dieser Kategorie werden über die LLM-Serving Schnittstelle der Telekom direkt an den jeweiligen Drittanbieter weitergeleitet, der diese auf eigenen Infrastrukturen betreibt.

Mit der Auswahl/Nutzung dieser Modelle akzeptiert der Kunde die Nutzungsbedingungen und Lizenzbestimmungen, insbesondere die Datenschutzbestimmungen, des jeweiligen Drittanbieters.

Der Drittanbieter kann Subunternehmer weltweit einsetzen, so dass die Daten des Kunden weltweit verarbeitet werden.

Aktuell sind folgende Modelle dieser Kategorie verfügbar:

| Modell | Modell-typ | Plattform |
|---|---|---|
| **OpenAI GPT-5.6 Sol Azure Sweden** | LLM | Microsoft Azure |
| **OpenAI GPT-5.6 Terra Azure Sweden** | LLM | Microsoft Azure |
| **OpenAI GPT-6.1 Sol Azure Sweden** | LLM | Microsoft Azure |
| **OpenAI GPT-6 Luna Azure Sweden** | LLM | Microsoft Azure |
| **OpenAI GPT-6 Astra Azure Sweden** | LLM | Microsoft Azure |
| **OpenAI GPT-Image-2** | LLM | Microsoft Azure |
| **OpenAI Ada-Text, Azure France** | Embedding | Microsoft Azure |
| **Mistral AI Mistral Medium 3.5** | LLM | Google Cloud Platform & Microsoft Azure |
| **Anthropic Claude Opus 5.5** | LLM | Google Cloud Platform & Microsoft Azure |
| **Anthropic Claude Sonnet 5.5** | LLM | Google Cloud Platform & Microsoft Azure |
| **Anthropic Claude Haiku 5.5** | LLM | Google Cloud Platform & Microsoft Azure |
| **Anthropic Claude Fable 5.1** | LLM | Google Cloud Platform & Microsoft Azure |
| **Google Gemini 3 Flash** | LLM | Google Cloud Platform |
| **Google Gemini 3.5 Flash** | LLM | Google Cloud Platform |
| **Google Gemini 3.8 Flash** | LLM | Google Cloud Platform |
| **Google Gemini 4 Argon** | LLM | Google Cloud Platform |

### 2.3.3 Testmodelle

Neben den produktiv nutzbaren Modellen stellt die Telekom dem Kunden weitere Large Language Models und Embedding-Modelle als Evaluierungsmodelle über die API unentgeltlich zur Verfügung. Die Evaluierungsmodelle dienen ausschließlich der technischen Erprobung und funktionalen Bewertung durch den Kunden; sie sind nicht für den produktiven Einsatz bestimmt.
Die Datenverarbeitung erfolgt ausschließlich innerhalb der EU/des EWR bzw. in Staaten mit einem geltenden Angemessenheitsbeschluss der Europäischen Kommission.
Die Nutzung der Evaluierungsmodelle ist unentgeltlich. Die Telekom ist berechtigt, den Nutzungsumfang jederzeit zu limitieren, insbesondere hinsichtlich des verfügbaren Token-Kontingents, der Rate-Limits (TPM/RPM) sowie der Nutzungsdauer.

Aktuell sind folgende Testmodelle verfügbar:

https://docs.llmhub.t-systems.net/plans/test

Die jeweils verfügbaren Evaluierungsmodelle werden im Self-Service-Portal des LLM-Serving-Service ausgewiesen und durch die Telekom fortlaufend aktualisiert. Ein Rechtsanspruch auf die Bereitstellung bestimmter oder sämtlicher dort aufgeführter Modelle besteht nicht.
Für Evaluierungsmodelle wird keine Mindestverfügbarkeit zugesagt. Die Telekom ist jedoch bestrebt, Leistungseinschränkungen im Rahmen ihrer technischen und betrieblichen Möglichkeiten gering zu halten.

**Nutzungsbedingungen und Einschränkungen**

Die Evaluierungsmodelle sind nicht für den Einsatz im Wirkbetrieb und nicht für die Verarbeitung von Echtdaten konzipiert. Setzt der Kunde die Evaluierungsmodelle gleichwohl im Wirkbetrieb oder mit Echtdaten ein, erfolgt dies in alleiniger Verantwortung des Kunden; eine Haftung der Telekom für hieraus resultierende Schäden ist – soweit gesetzlich zulässig – ausgeschlossen.
Die Telekom ist jederzeit und ohne Angabe von Gründen berechtigt, einzelne oder sämtliche Evaluierungsmodelle einzustellen, zu ändern oder den Zugang des Kunden ganz oder teilweise zu beschränken. Der Kunde hat keinen Rechtsanspruch auf die fortlaufende oder unveränderte Bereitstellung der Evaluierungsmodelle.
Da es sich um einen Evaluierungsbetrieb handelt, muss mit eingeschränkter Leistungsfähigkeit gerechnet werden. Die Telekom ist bestrebt, etwaige Leistungsstörungen im Rahmen ihrer technischen und betrieblichen Möglichkeiten zeitnah zu beheben und den Evaluierungsbetrieb fortlaufend zu optimieren.

# 3 Leistungen der Telekom

## 3.1 Bereitstellung

Die Telekom richtet den LLM-Serving-Service gemäß Beauftragung ein und versendet die Zugangsdaten nebst URL für das LLM-Self-Service-Portal sowie den relevanten Kontakt-E-Mail-Adressen per E-Mail an den Kunden.

Die Bereitstellung ist mit Versendung der E-Mail, spätestens mit Nutzungsbeginn durch den Kunden abgeschlossen.

## 3.2 Betrieb

### 3.2.1 Kundensupport

Der Kundensupport der Telekom ist der zentrale Ansprechpartner für die benannten Administratoren des Kunden als 2nd-Level-Support und erbringt folgende Leistungen:

a. Bearbeitung von Incidents
b. Beantwortung von Service-Requests

Der Kundensupport ist unter der dem Kunden im Rahmen der Bereitstellung mitgeteilten E-Mail-Adresse erreichbar während der betreuten Betriebszeit (Montag bis Freitag von 9:00 Uhr bis 17:00 Uhr MEZ/MESZ, ausgenommen an bundeseinheitlichen Feiertagen in Deutschland) erreichbar.

Anfragen des Kunden bearbeitet die Telekom nach folgendem Prozess:

a. Die Telekom eröffnet ein Ticket, versendet per E-Mail eine Eingangsbestätigung der Anfrage nebst Ticketnummer.
b. Die Telekom analysiert die Anfrage des Kunden und setzt sich soweit erforderlich zwecks Klärung von Fragen mit diesem in Verbindung.

c. Die Telekom informiert den Kunden per E-Mail über den Status und den Abschluss der Bearbeitung.

Für die Bearbeitung von Tickets gilt:

a. Tickets werden ausschließlich innerhalb der betreuten Betriebszeit bearbeitet.
b. Für die Bearbeitung von Incidents gelten keine zugesagten Lösungszeiten.
c. Die Telekom ist berechtigt, Incidents durch die Bereitstellung eines Workarounds zu beheben.

### 3.2.2 Leistungsübergabepunkt

Die Verantwortung der Telekom endet am Leistungsübergabepunkt. Der Leistungsübergabepunkt ist der API Endpoint des LLM-Serving-Services im Rechenzentrum der Telekom.

### 3.2.3 Service Quality

#### a. Mindestverfügbarkeit

Die Mindestverfügbarkeit des LLM-Serving-Services am Leistungsübergabepunkt für Tarife mit Mindestumsatz liegt bei 99,5% innerhalb der betreuten Betriebszeit eines Kalendermonats und wird wie folgt berechnet:

$$\left[\left(\frac{\text{Gesamte Serviceminuten} - \text{Gesamte Ausfallminuten}}{\text{Gesamte Serviceminuten}}\right) * 100\right]$$

Die Mindestverfügbarkeit wird als Prozentsatz ausgewiesen. Dabei bedeutet:

**Gesamte Serviceminuten** – die gesamte Anzahl der Minuten während der betreuten Betriebszeit innerhalb eines Kalendermonats.

**Gesamte Ausfallminuten** – die Anzahl der Minuten innerhalb der betreuten Betriebszeit innerhalb eines Kalendermonats, in der der LLM-Serving-Service nicht verfügbar ist abzüglich der ausgeschlossenen Ereignisse (Excused Events) in Minuten.

Im Übrigen gilt keine Mindestverfügbarkeit. Die Telekom ist jedoch bemüht, Leistungseinschränkungen zu vermeiden.

#### b. Excused Events (Ausgeschlossene Ereignisse/Suspend-Zeiten)

Unterbrechungen der Leistung, die auf einem den nachfolgenden Ereignissen basieren, gelten nicht als Ausfallminuten:

i. Ausfälle, die durch Wartungsarbeiten verursacht werden;
ii. Störungen, Ausfälle und Probleme die auf den Kunden, seine Mitarbeiter oder sonst dem Kunden zuzurechnender Dritter zurückzuführen sind.
iii. Ausfälle, die auf eine Einwirkung von Dritten oder höhere Gewalt zurückzuführen sind.

iv. Störungen, Ausfälle und Probleme, die auf Leistungen von Drittanbietern, insbesondere im Zusammenhang der Bereitstellung von LLMs mit Betrieb außerhalb EU zurückzuführen sind.

**c. Service Credits**

Bei Nichteinhaltung der Mindestverfügbarkeit erstattet die Telekom dem Kunden nachfolgende Service Credits unter folgenden Voraussetzungen:

i. Die Telekom hat die Nichteinhaltung der vereinbarten Verfügbarkeit im jeweiligen Abrechnungszeitraum ausschließlich zu vertreten.
ii. Die Service Credits werden durch den Kunden via E-Mail an die im Rahmen der Bereitstellung zur Verfügung gestellte E-Mail-Adresse innerhalb einer Frist von drei Monaten ab dem Abrechnungszeitraum geltend gemacht.
iii. Die Höhe der Gutschrift des jeweiligen Abrechnungszeitraums beträgt mindestens 1,00 EUR.
iv. Die Telekom prüft den Anspruch des Kunden und teilt diesem im Falle eines positiven Prüfungsergebnisses die Höhe der Erstattung mit.
v. Die Telekom verrechnet die Service Credits mit der auf die Bestätigung folgenden Monatsrechnung, bzw. überweist diese nach Beendigung der Leistung an die kundenseitig benannte Bankverbindung.

Die Höhe der Service Credits wird abhängig von dem vom Kunden für den jeweiligen Abrechnungszeitraum tatsächlich gezahlten Mindestumsatzes wie folgt berechnet:

| **Verfügbarkeit im jeweiligen Abrechnungszeitraum** | **Höhe der Servicecredits für die betroffene Leistung** |
|---|---|
| <99,5% - 99,3% | 5% des vereinbarten Mindestumsatzes |
| <99,3 – 95% | 10% des vereinbarten Mindestumsatzes |
| <95% | 25% des vereinbarten Mindestumsatzes |

Gewährte Service Credits werden auf etwaige Schadensersatzansprüche und sonstige Ansprüche auf Grund der Nichteinhaltung der Verfügbarkeit des Kunden angerechnet. Diese Regelung ist abschließend.

### 3.2.4 Wartungsarbeiten

Die Telekom führt regelmäßig Wartungsarbeiten durch. Sollten diese Wartungsarbeiten zu Unterbrechungen der Leistung führen, wird die Telekom den Kunden vorab informieren. Die Telekom ist hierbei bestrebt, Beeinträchtigungen durch Wartungsarbeiten möglichst gering zu halten. Wartungsarbeiten gelten nicht als Ausfallzeiten und bleiben daher bei der Berechnung der Verfügbarkeit unberücksichtigt.

### 3.2.5 Reporting

Die Telekom stellt dem Kunden in den Tarifen mit Mindestumsatz auf Anfrage ein monatliches Reporting mit folgendem Inhalt bereit:

| | |
|---|---|
| Verfügbarkeit (Übersicht) | Einhaltung der Mindestverfügbarkeit |
| Verfügbarkeit (Details) | Umfasst die monatlichen Details zur Verfügbarkeit des API-Endpoints, sowie eine 6-monatige Historie zur Auskunft über Ausfallhäufigkeiten und –zeiten.<br>Des Weiteren werden die Bereitschafts- und Ausfallzeiten des aktuellen Monats sowohl in grafischer als auch tabellarischer Form dargestellt. |
| Ausfallzeit in Minuten | Protokoll aller Ausfallzeiten innerhalb der betreuten Betriebszeit für den aktuellen Monat. |
| Legende | Erklärungen zu den einzelnen Bestandteilen des Reports. |
| Änderungshistorie | Versionsbeschreibung |

Der Report wird dem Kunden auf Anfrage fünf Werktage nach Ablauf eines Kalendermonats per E-Mail zugesandt.

## 3.3 Nutzungsbedingungen, Lizenzbestimmungen

### 3.3.1 Einhaltung der KI-Verordnung

Die Telekom verpflichtet sich, die im Rahmen dieses Vertrages für den Kunden erbrachten Leistungen, soweit diese den Anwendungsbereich der Verordnung (EU) 2024/1689 über Künstliche Intelligenz (KI-Verordnung) betreffen, im Einklang mit den jeweils auf die Telekom anwendbaren Pflichten der KI-Verordnung zu erbringen. Weitergehende Verpflichtungen oder Garantien werden nicht übernommen. Etwaige leistungs- /produktspezifische Vereinbarungen gelten vorrangig.

Der Kunde verpflichtet sich, die im Rahmen dieses Vertrages erbrachten IT-Leistungen im Einklang mit der KI-Verordnung zu nutzen.

### 3.3.2 Allgemeine Nutzungsbedingungen

Die Telekom stellt dem Kunden mit dem LLM-Serving-Service einen KI-Service zur Verfügung, der den Zugriff auf verschiedene LLMs zur eigenverantwortlichen Nutzung ermöglicht.

Die durch den KI-Service generierten Ergebnisse unterliegen weder der Kontrolle noch dem Einfluss der Telekom. Die Telekom ist daher, soweit gesetzlich zulässig, nicht für die durch den KI-Service generierten Ergebnisse und deren Verwendung durch den Kunden, insbesondere im Hinblick auf die Freiheit von Rechten Dritter, verantwortlich.

Durch die Nutzung des KI-Service erklärt sich der Kunde mit folgenden Bedingungen einverstanden:

a. Der Kunde stellt bei der Nutzung der Leistung, sowie der Verwendung von generierten Ergebnissen sicher, dass er in diesem Zusammenhang aller für ihn anwendbaren

rechtlichen Vorschriften, insbesondere der Vorschriften des EU AI Act, datenschutzrechtlicher Bestimmungen (z.B. Zulässigkeitsvoraussetzungen wie Mindestalter) und sonstiger branchenspezifischen Bedingungen oder interner Vorgaben einhält.

b. Der Einsatz von KI kann fehlerhafte, unvollständige, beleidigende oder durch Rechte Dritter geschützte Inhalte liefern. Der Kunde verpflichtet sich, eine Überwachung des KI-Einsatzes sicherzustellen und seine Nutzer zum KI-Einsatz zu informieren, insbesondere wird der Kunde
   - generierte Ergebnisse für den jeweiligen Anwendungsfall auf Richtigkeit und Angemessenheit durch eine menschliche Überprüfung bewerten, bevor er die generierten Ergebnisse verwendet oder weitergibt.
   - sich nicht auf die generierten Ergebnisse verlassen oder Entscheidungen ausschließlich basierend auf den generierten Ergebnissen treffen, insbesondere, wenn er medizinischen, rechtlichen, finanziellen oder anderen professionellen Rat sucht.
   - generierte Ergebnisse, die sich auf eine Person beziehen, nicht für einen Zweck verwenden, der rechtliche oder wesentliche Auswirkungen auf diese Person haben könnte, wie z. B. das Treffen von Kredit-, Bildungs-, Beschäftigungs-, Versicherungs-, rechtlichen, medizinischen oder anderen wichtigen Entscheidungen.

### 3.3.3 Lizenzen, Nutzungsbedingungen und Datenschutzbestimmungen

Durch die Nutzung der jeweiligen LLMs und Embedding Modelle akzeptiert der Kunde die folgend aufgeführten Nutzungsbedingungen, einschließlich der Datenschutzbestimmungen und Lizenzbedingungen für das jeweilige Model in ihrer jeweils aktuellen Fassung, wodurch eine Vereinbarung zwischen dem Kunden und dem jeweiligen Anbieter zustande kommt:

| Modell | Plattform | Nutzungs-bedingungen | Datenschutz-bestimmun-gen |
|---|---|---|---|
| OpenAI Ada Text<br>OpenAI GPT-Image-2<br>OpenAI GPT-5.6 Sol<br>OpenAI GPT-5.6 Terra<br>OpenAI GPT-6.1 Sol<br>OpenAI GPT-6 Luna<br>OpenAI GPT-6 Astra<br>Anthropic Claude Sonnet 5.5<br>Anthropic Claude Haiku 5.5<br>Anthropic Claude Opus 5.5<br>Anthropic Claude Fable 5.1<br>Mistral AI Mistral Medium 3.5 | Microsoft Azure | https://www.microsoft.com/licensing/terms/productoffering/MicrosoftAzure/MCA#ServiceSpecificTerms | https://www.microsoft.com/licensing/docs/view/Microsoft-Products-and-Services-Data-Protection-Addendum-DPA |

| Modell | Plattform | Nutzungs-bedingungen | Datenschutz-bestimmun-gen |
|---|---|---|---|
| Anthropic Claude Sonnet 5.5<br>Anthropic Claude Haiku 5.5<br>Anthropic Claude Opus 5.5<br>Anthropic Claude Fable 5.1<br>Mistral AI Mistral Medium<br>Google Gemini 3 Flash<br>Google Gemini 3.5 Flash<br>Google Gemini 3.8 Flash<br>Google Gemini 4 Argon | Google Cloud Platform | https://cloud.google.com/terms/services<br>https://cloud.google.com/terms/aup | https://cloud.google.com/terms/data-processing-terms<br>https://cloud.google.com/terms/cloud-privacy-notice |
| Jina AI jina-embeddings-v2-base-de<br>OpenAI Whisper Large v3<br>Qwen3.6 35B | T-Cloud Public, Open Source | https://www.apache.org/licenses/LICENSE-2.0.html | |
| OpenAI Whisper Large v3 Turbo | T-Cloud Public, Open Source | https://choosealicense.com/licenses/mit/ | |
| BAAI text-embedding-bge-m3 | T-Cloud Public, Open Source | https://opensource.org/license/mit | |
| GLM 5.3 Flash | T-Cloud Public, Industrial AI Cloud, Open Source | https://opensource.org/license/mit | |
| GLM 5.3 | T-Cloud Public, Industrial AI Cloud, Open Source | https://huggingface.co/zai-org/GLM-5.3/blob/main/LICENSE | |
| OpenAI GPT-OSS-120B<br>Gemma 4 31B<br>Mistral AI Mistral Small 4<br>Qwen 3.8 27B<br>LightOnOCR-3-4B<br>PaddleOCR-VL-1.6<br>Qwen3-Reranker-4B<br>Qwen3-Embedding-8B | T-Cloud Public, Industrial AI Cloud, Open Source | https://www.apache.org/licenses/LICENSE-2.0.html | |
| NVIDIA Nemotron 3 Super | T-Cloud Public, Industrial AI Cloud, Open Source | https://www.nvidia.com/en-us/agreements/enterprise-software/nvidia-open-model-license/ | |

### 3.3.4 Medical Device Regulation (MDR)

Der LLM-Serving-Service ist kein Medizinprodukt im Sinne von Art. 2 Nr.1 MDR. Der Kunde verpflichtet sich, den LLM-Serving-Service nicht als Medizinprodukt und insbesondere nicht zu folgenden Zwecken einzusetzen:

- Diagnose, Verhütung, Überwachung, Vorhersage, Prognose, Behandlung oder Linderung von Krankheiten,
- Diagnose, Überwachung, Behandlung, Linderung von oder Kompensierung von Verletzungen oder Behinderungen,
- Untersuchung, Ersatz oder Veränderung der Anatomie oder eines physiologischen oder pathologischen Vorgangs oder Zustands,
- Gewinnung von Informationen durch die In-vitro-Untersuchung von aus dem menschlichen Körper — auch aus Organ-, Blut- und Gewebespenden — stammenden Proben

### 3.3.5 Hochrisiko-KI-Systeme, Verbotene Anwendungsfälle

Die Telekom erbringt die vertraglichen Leistungen ausschließlich auf Grundlage der vereinbarten Zweckbestimmung. Diese schließt die Nutzung als Hochrisiko-KI-System oder jegliche verbotene Anwendung im Sinne der KI-Verordnung aus. Der Kunde sichert zu, die Leistungen der Telekom nicht als Hochrisiko-KI-System oder zu verbotenen Zwecken im Sinne der KI-Verordnung einzusetzen oder einsetzen zu lassen.

### 3.3.6 Haftung, Freistellung, Kündigung

Bei wiederholten oder schwerwiegenden Verstößen des Kunden gegen diese Nutzungs- und Lizenzbestimmungen ist die Telekom berechtigt, den Vertrag aus wichtigem Grund ohne Einhaltung einer Frist zu kündigen zu kündigen.

Die Telekom haftet, soweit gesetzlich zulässig, nicht für Schäden, die aus der Nichteinhaltung dieser Nutzungs- und Lizenzbestimmungen resultieren.

Zudem stellt der Kunde die Telekom diesbezüglich von allen Ansprüchen Dritter (insb. Aufsichtsbehörden) auf erstes Anfordern vollumfänglich frei. Weitergehende Ansprüche der Telekom bleiben unberührt.

### 3.3.7 Feedback

Der Kunde räumt der Telekom und ihren verbundenen Unternehmen ein uneingeschränktes Nutzungsrecht an dessen Feedback und Ideen zu den beschriebenen Leistungen ein.

## 3.4 Optionale Leistungen

Die nachfolgenden optionalen Leistungen werden bei gesonderter Beauftragung gegen zusätzliche Vergütung erbracht. Auf Anfrage beim zuständigen Telekom-Vertriebsmitarbeiter wird die Telekom dem Kunden nach erfolgreicher Prüfung ein Angebot, sowie detaillierte Beschreibungen der Leistungen zur Verfügung stellen.

### 3.4.1 LLMs auf dedizierter Instanz

Die Telekom stellt einzelne LLMs und Embeddings auf einer dedizierten Instanz bereit. Der Kunde hat so exklusiven Zugang zu dem jeweiligen Sprachmodell, ohne es mit anderen Kunden zu teilen.

### 3.4.2 Feintuning von Modellen

Der LLM-Serving-Service kann um Funktionalitäten für das Feintuning von LLMs erweitert werden. Auf Anfrage stellt die Telekom die Funktionalität samt Dokumentation zur Verfügung und unterstützt bei der Erstellung und Integration des feingetunten Modells in die Gesamtlösung.

### 3.4.3 Installation auf einer kundeneigenen Umgebung

Auf Anfrage prüft die Telekom die Möglichkeiten der Bereitstellung der Leistung auf einer kundeneigenen Umgebung. Ergibt die Prüfung der Telekom, dass die Umgebung des Kunden die erforderlichen Anforderungen erfüllt, stellt die Telekom die Leistungen im Rahmen einer kundenspezifischen Lösung auf dessen Umgebung bereit und übernimmt bei entsprechender Beauftragung den Betrieb der kundenspezifischen Lösung.

### 3.4.4 Zusätzliche LLMs und Embedding Modelle

Die Telekom stellt dem Kunden LLMs und Embedding Modelle, die nicht zu den aktuell verfügbaren LLMs und Embedding Modellen gehören, auf einer kundeneigenen oder dedizierten Instanz bereit. Die Telekom unterbreitet dem Kunden ein entsprechendes Angebot, bei Vorliegen eines positiven Prüfungsergebnisses zur technischen Machbarkeit.

### 3.4.5 Weitere Unterstützungsleistungen

Die Telekom unterstützt den Kunden individuell mit folgenden Dienstleistungen auf Basis von Time & Material:

- Implementierungssupport
- Beratung/Coaching / Schulung

# 4 Leistungsänderungen durch Telekom

Beabsichtigt die Telekom Änderungen der rechtlichen Bedingungen dieser Leistungsbeschreibung, der Leistungen oder Preise vorzunehmen, so werden die Änderungen dem Kunden mindestens einen Monat vor ihrem Wirksamwerden in Textform (z. B. per Brief oder E-Mail) mitgeteilt. Die Änderungen werden unter den nachfolgenden Voraussetzungen der Ziffern a) bis b) Vertragsbestandteil:

a. Änderungen zu Gunsten des Kunden zum Zeitpunkt ihres Wirksamwerdens.
b. Preiserhöhungen, Änderungen der rechtlichen Bedingungen und nicht lediglich unerheblichen Änderungen der Leistungen zu Ungunsten des Kunden zum Zeitpunkt ihres Wirksamwerdens. Dies gilt nicht, sofern der Kunde die Leistung ohne Einhaltung einer Kündigungsfrist zu diesem Zeitpunkt in Textform kündigt. Auf das Kündigungsrecht wird der Kunde in der Änderungsmitteilung ausdrücklich hingewiesen.

# 5 Mitwirkungsleistungen des Kunden

Der Kunde ist verpflichtet alle Leistungen, die zur ordnungsgemäßen Leistungserbringung durch Telekom erforderlich sind, insbesondere jedoch nachfolgende, unentgeltlich, rechtzeitig und im erforderlichen Umfang zu erbringen:

## 5.1 Allgemeine Mitwirkungsleistungen

a. Der Kunde ist verpflichtet, einen qualifizierten und entscheidungsbefugten Ansprechpartner zu benennen und dessen Erreichbarkeit/Vertretung sicherzustellen.
b. Der Kunde benennt bis zu 5 Administratoren, die ausreichend qualifiziert und berechtigt sind, Supportanfragen an die Telekom zu stellen
c. Der Kunde erklärt sich mit dem unverschlüsselten Schriftwechsel per E-Mail einverstanden und wird stets eine aktuelle E-Mail Adresse hinterlegen. Dem Kunden ist bekannt, dass für die Leistungserbringung wesentliche Informationen, wie Zugangsdaten, Informationen zu Änderungen der Leistungen und der rechtlichen Bedingungen, sowie Rechnungen ausschließlich per Mail versendet werden.
d. Der Kunde prüft eigenverantwortlich, ob die von ihm im Zusammenhang mit der Nutzung der Leistung an die Telekom übermittelten Daten personenbezogene Daten darstellen und die Verarbeitung dieser personenbezogenen Daten zulässig ist. Sofern der Kunde personenbezogene Daten verarbeiten lassen möchte, wird dieser eine Vereinbarung über die Verarbeitung personenbezogener Daten nach dem Muster der Telekom abschließen, welches die Telekom dem Kunden auf Anfrage zur Verfügung stellt.
e. Der Kunde prüft eigenverantwortlich alle für ihn im Zusammenhang mit der Nutzung der Leistung relevanten und anwendbaren rechtlichen Vorschriften, Gesetze, Verordnungen und branchenspezifischen Bestimmungen und stellt deren Einhaltung sicher. Dazu zählen insbesondere auch die Einhaltung von Geheimhaltungsverpflichtungen, die z.B. aus einer beruflichen Tätigkeit herrühren, sowie die Einhaltung der Nutzungs- und Lizenzbestimmungen.
f. Der Kunde stellt sicher, dass die Leistungen nicht missbräuchlich genutzt werden.
g. Der Kunde stellt der Telekom alle erforderlichen Informationen zur Verfügung und stellt sicher, dass seine Angaben inhaltlich richtig und stets aktuell sind.

h. Der Kunde ist verpflichtet Einrichtungen und Leistungen der Telekom vor unberechtigtem Zugriff, Schadsoftware und sonstigen Beeinträchtigungen durch geeignete Maßnahmen zu schützen, diese pfleglich zu behandeln und die Angaben der Hersteller zu beachten.
i. Der Kunde ist verpflichtet Passwörter und Zugangsdaten, insbesondere von ihm generierte API-Keys, geheim zu halten, nur an berechtigte Dritte weiterzugeben, bzw. vor deren Zugriff zu schützen und soweit erforderlich zu ändern. Der Kunde wird die Telekom unverzüglich bei Anhaltspunkten der Kenntnisnahme durch unberechtigte Dritte informieren.
j. Support
   Der Kunde ist verpflichtet, die Telekom bei der Behebung einer Störung/Beeinträchtigung zu unterstützen.
   Insbesondere erbringt der Kunde für seine Nutzer einen 1st Level Support (User Helpdesk) und führt in diesem Rahmen eine Selbstprüfung durch, um auszuschließen, dass die Störungsursache in seinem Verantwortungsbereich liegt. Der Kunde behebt alle Störungen in seinem Verantwortungsbereich eigenständig.
   Soweit der Kunde Störungen nicht eigenständig beheben kann und diese durch die Telekom zu vertreten sind, meldet der Kunde diese Störungen dem Support der Telekom mit einer nachvollziehbaren Schilderung der Fehlersymptome und unter Angabe sonstiger relevanter Informationen.
   Der Kunde ist verpflichtet Störungen, Beeinträchtigungen der Leistungen oder Beschädigungen an den Einrichtungen der Telekom unverzüglich anzuzeigen.
k. Der Kunde ist verpflichtet, für eine ausreichende Deckung des vereinbarten Abbuchungskontos zu sorgen, sowie im Falle der Zahlung per Kreditkarte seine bei der Registrierung hinterlegten Kreditkartendaten auf dem aktuellen Stand zu halten.
l. Für den Zugriff auf den API-Endpoint via der Python-Bibliothek „openai“ stellt der Kunde die benötigte Software bei und stellt sicher, dass diese stets aktuell ist.
m. Der Kunde stellt sicher, dass er über die erforderlichen Nutzungsrechte (einschließlich Updates oder Upgrades) verfügt.
n. Der Kunde stellt die Einhaltung der Bestimmungen dieser Leistungsbeschreibung, insbesondere der Mitwirkungsleistungen, sowie Nutzungs- und Lizenzbestimmungen durch seine Nutzer sicher.
o. Der Kunde wird die Telekom unverzüglich in Textform informieren, wenn er eine Mitwirkungsleistung nicht wie vereinbart erbringen kann, oder Umstände eintreten, die der Telekom die Erbringung der Leistungen erschweren oder unmöglich machen.

## 5.2 Mitwirkungsleistungen bei Betrieb

a. Der Kunde stellt sicher, dass er keine Daten, Inhalte oder sonstige Eingaben verwendet, auf dem vertragsgegenständlichen Speicherplatz speichert oder sonst zugänglich macht, die Malicious Codes oder sonstige Schadsoftware enthalten, und/oder deren Bereitstellung, Veröffentlichung, Übertragung oder Nutzung gegen geltendes Recht oder Rechte Dritter verstößt.
b. Der Kunde stellt sicher, dass von seiner Nutzung der Leistung keine Gefährdung oder Störung Dritter oder der Einrichtungen und Leistungen der Telekom ausgeht. Im Falle einer solchen Gefährdung oder Störung (z.B. auf Grund einer DDoS Attacke) ist die Telekom ohne vorherige Benachrichtigung des Kunden berechtigt, die betroffene Leistung bis zur Beseitigung der Ursache der Gefährdung oder Störung zu deaktivieren. Die hierdurch entstehenden Ausfallzeiten bleiben bei der Berechnung der Verfügbarkeit unberücksichtigt. Die Telekom wird den Kunden informieren.

c. Der Kunde informiert die Telekom unverzüglich über alle mutmaßlichen, die Einrichtungen und Leistungen der Telekom betreffenden, sicherheitsrelevanten Vorfälle.

# 6 Mindestlaufzeit/Beendigung

Die Leistung ist mit einer Frist von einem Monat zum Monatsende kündbar. Alle Kündigungen haben per E-Mail an die im Rahmen der Bereitstellung bekanntgegebene E-Mail-Adresse unter Angabe der Vertragsnummer zu erfolgen.

Mit Beendigung des LLM-Serving-Services werden alle Zugangsmöglichkeiten deaktiviert und die Daten des Kunden gelöscht.

Das Recht zur außerordentlichen Kündigung bleibt hiervon unberührt.

# 7 Preise, Kommerzielle Bedingungen

## 7.1 Verfahren der Entgeltberechnung

a) Tokenverbrauch

Die Nutzung der Modelle wird basierend auf der Anzahl der verbrauchten Tokens abgerechnet. Der Tokenverbrauch ist im LLM-Self-Service-Portal einsehbar. Die Abrechnung erfolgt je angefangener Million Input-/Output-Tokens für das jeweilige Modell.

b) Tarife

Die Telekom stellt den LLM-Serving-Service in unterschiedlichen Tarifen bereit. Diese Tarife unterscheiden sich in den folgenden Aspekten:

- Verfügbare Modelle
- Max. Input TPM (Token per Minute): Maximale Anzahl von verarbeiteten Input-Token pro Minute
- Max. Output TPM (Token per Minute): Maximale Anzahl von verarbeiteten Output-Token pro Minute
- Max. RPM (Requests per Minute): Maximale Anzahl von Anfragen pro Minute, die an das LLM gestellt werden können

Bei Tarifen mit Mindestumsatz berechnet die Telekom auch bei einer den Mindestumsatz unterschreitenden Nutzung des Kunden den jeweiligen Mindestumsatz.
Bei untermonatlicher Bereitstellung/Beendigung eines Tarifs wird der Mindestumsatz anteilig nach Kalendertagen berechnet. Tarifwechsel sind auf Anfrage einvernehmlich möglich.

Die Telekom weist darauf hin, dass es sich bei den Werten Max Input TPM, Max Output TPM, Max RPM um maximal mögliche Rate-Limits handelt. Die tatsächlich zu erwartenden Durchsätze werden darunter liegen.

c) Rechnungsstellung

Die Telekom stellt dem Kunden für den jeweils vorangegangenen Kalendermonat monatlich eine Rechnung.

d) Steuern und Abgaben

Alle Preise sind in Euro angegeben und verstehen sich zuzüglich der zum Zeitpunkt der Lieferung und Leistung geltenden Steuern und Abgaben.

## 7.2 Preise

Für alle über T-Cloud Public / Industrial AI Cloud gehosteten Modelle beträgt der Preis für zwischengespeicherte Input-Token (Cached Input) 15 % des jeweiligen Input-Token-Preises.

### 7.2.1 Tarif Essential

Der monatliche Mindestumsatz für Modelle im Tarif Essential beträgt: 1.000 €.

| Plattform | Modell | Modell-typ | Max. Input TPM | Max. Output TPM | Max. RPM | Preis pro Million Input-Token | Preis pro Million Output-Token |
|---|---|---|---|---|---|---|---|
| T-Cloud Public | **Jina AI jina-embeddings-v2-base-de** | Em-bedding | 300.000 | 150.000 | 300 | 0,05 € | 0,05 € |
| T-Cloud Public | **BAAI text-embedding-bge-m3** | Em-bedding | 300.000 | 150.000 | 300 | 0,05 € | 0,05 € |
| T-Cloud Public / Industrial AI Cloud | **Qwen3-Embedding-8B** | Em-bedding | 180.000 | | 360 | 0,10 € | 0,10 € |
| T-Cloud Public / Industrial AI Cloud | **Qwen3-Reranker-4B** | Reranker | 600.000 | | 240 | 0,05 € | 0,05 € |
| T-Cloud Public | **OpenAI Whisper Large v3** | STT | 218 | | 300 | 14,61 € | 14,61 € |
| T-Cloud Public | **OpenAI Whisper Large v3 Turbo** | STT | 345 | | 300 | 9,21 € | 9,21 € |
| T-Cloud Public / Industrial AI Cloud | **OpenAI GPT-OSS-120B** | LLM | 400.000 | 400.000 | 100 | 0,20 € | 0,65 € |
| T-Cloud Public / Industrial AI Cloud | **Gemma 4 31B**<br>**Mistral AI Mistral Small 4**<br>**NVIDIA Nemotron 3 Super** | LLM | 50.000 | 50.000 | 50 | 0,60 € | 1,20 € |
| T-Cloud Public | **Qwen3.6 35B** | LLM | 50.000 | 50.000 | 50 | 0,60 € | 1,20 € |
| T-Cloud Public / Industrial AI Cloud | **Qwen 3.8 27B** | LLM | 50.000 | 50.000 | 50 | 0,50 € | 2,50 € |
| T-Cloud Public / Industrial AI Cloud | **GLM 5.3** | LLM | 480.000 | 60.000 | 60 | 1,40 € | 4,40 € |
| T-Cloud Public / Industrial AI Cloud | **GLM 5.3 Flash** | LLM | 400.000 | 400.000 | 100 | 0,20 € | 0,60 € |
| T-Cloud Public / Industrial AI Cloud | **LightOnOCR-3-4B** | OCR | 60.000 | 22.500 | 18 | 0,20 € | 0,60 € |
| T-Cloud Public / Industrial AI Cloud | **PaddleOCR-VL-1.6** | OCR | 82.500 | 75.000 | 60 | 0,10 € | 0,40 € |
| Microsoft Azure | **OpenAI GPT-5.6 Sol Azure Sweden** | LLM | 250.000 | 125.000 | 250 | 4,50 € | 27,00 € |

| Plattform | Modell | Modell-typ | Max. Input TPM | Max. Output TPM | Max. RPM | Preis pro Million Input-Token | Preis pro Million Output-Token |
|---|---|---|---|---|---|---|---|
| Microsoft Azure | **OpenAI GPT-5.6 Terra Azure Sweden** | LLM | 750.000 | 375.000 | 750 | 3,52 € | 15,82 € |
| Microsoft Azure | **OpenAI GPT-6.1 Sol Azure Sweden <=272k Input-Tokens** | LLM | 250.000 | 125.000 | 250 | 2,14 € | 10,68 € |
| Microsoft Azure | **OpenAI GPT-6.1 Sol Azure Sweden >272k Input-Tokens** | LLM | 250.000 | 125.000 | 250 | 4,28 € | 16,02 € |
| Microsoft Azure | **OpenAI GPT-6 Luna Azure Sweden <=272k Input-Tokens** | LLM | 250.000 | 125.000 | 250 | 0,11 € | 0,54 € |
| Microsoft Azure | **OpenAI GPT-6 Luna Azure Sweden >272k Input-Tokens** | LLM | 250.000 | 125.000 | 250 | 0,22 € | 0,81 € |
| Microsoft Azure | **OpenAI GPT-Image-2 (Input Text, Output Image)** | LLM | | | 1 | 4,39 € | 26,33 € |
| Microsoft Azure | **OpenAI GPT-Image-2 (Input Image, Output Image)** | LLM | | | 1 | 7,03 € | 26,33 € |
| Microsoft Azure | **OpenAI Ada-Text, Azure France** | Em-bedding | 3.000.000 | 1.500.000 | 3.000 | 0,11 € | 0,11 € |
| Google Cloud Platform & Microsoft Azure | **Mistral AI Mistral Medium 3.5** | LLM | 120.000 | 60.000 | 90 | 1,29 € | 6,44 € |
| Google Cloud Platform & Microsoft Azure | **Anthropic Claude Sonnet 5.5** | LLM | 5.625.000 | 562.500 | 562 | 2,97 € | 14,85 € |
| Google Cloud Platform & Microsoft Azure | **Anthropic Claude Haiku 5.5 <=100k Input-Tokens** | LLM | 6.750.000 | 675.000 | 600 | 0,10 € | 0,50 € |
| Google Cloud Platform & Microsoft Azure | **Anthropic Claude Haiku 5.5 >100k Input-Tokens** | LLM | 6.750.000 | 675.000 | 600 | 0,50 € | 2,48 € |
| Google Cloud Platform | **Google Gemini 3 Flash** | LLM | DSQ | DSQ | DSQ | 0,45 € | 2,70 € |
| Google Cloud Platform | **Google Gemini 3.5 Flash** | LLM | DSQ | DSQ | DSQ | 1,49 € | 8,91 € |
| Google Cloud Platform | **Google Gemini 3.8 Flash** | LLM | DSQ | DSQ | DSQ | 0,74 € | 3,68 € |
| Google Cloud Platform | **Google Gemini 4 Argon** | LLM | DSQ | DSQ | DSQ | 3,96 € | 19,80 € |

### 7.2.2 Tarif Professional

Der monatliche Mindestumsatz für Modelle im Tarif Professional beträgt: 3.000 €

| Plattform | Modell | Modell-typ | Max. Input TPM | Max. Output TPM | Max. RPM | Preis pro Million Input-Token | Preis pro Million Output-Token |
|---|---|---|---|---|---|---|---|
| T-Cloud Public | **Jina AI jina-embeddings-v2-base-de** | Em-bedding | 600.000 | 300.000 | 600 | 0,05 € | 0,05 € |
| T-Cloud Public | **BAAI text-embedding-bge-m3** | Em-bedding | 600.000 | 300.000 | 600 | 0,05 € | 0,05 € |
| T-Cloud Public / Industrial AI Cloud | **Qwen3-Embedding-8B** | Em-bedding | 360.000 | | 720 | 0,10 € | 0,10 € |
| T-Cloud Public / Industrial AI Cloud | **Qwen3-Reranker-4B** | Reranker | 1.200.000 | | 480 | 0,05 € | 0,05 € |
| T-Cloud Public | **OpenAI Whisper Large v3** | STT | 218 | | 300 | 14,61 € | 14,61 € |
| T-Cloud Public | **OpenAI Whisper Large v3 Turbo** | STT | 345 | | 300 | 9,21 € | 9,21 € |
| T-Cloud Public / Industrial AI Cloud | **OpenAI GPT-OSS-120B** | LLM | 1.000.000 | 1.000.000 | 200 | 0,20 € | 0,65 € |
| T-Cloud Public / Industrial AI Cloud | **Gemma 4 31B**<br>**Mistral AI Mistral Small 4**<br>**NVIDIA Nemotron 3 Super** | LLM | 100.000 | 100.000 | 100 | 0,60 € | 1,20 € |
| T-Cloud Public | **Qwen3.6 35B** | LLM | 100.000 | 100.000 | 100 | 0,60 € | 1,20 € |
| T-Cloud Public / Industrial AI Cloud | **Qwen 3.8 27B** | LLM | 100.000 | 100.000 | 100 | 0,50 € | 2,50 € |
| T-Cloud Public / Industrial AI Cloud | **GLM 5.3** | LLM | 960.000 | 120.000 | 120 | 1,40 € | 4,40 € |
| T-Cloud Public / Industrial AI Cloud | **GLM 5.3 Flash** | LLM | 1.000.000 | 1.000.000 | 200 | 0,20 € | 0,60 € |
| T-Cloud Public / Industrial AI Cloud | **LightOnOCR-3-4B** | OCR | 120.000 | 45.000 | 36 | 0,20 € | 0,60 € |
| T-Cloud Public / Industrial AI Cloud | **PaddleOCR-VL-1.6** | OCR | 165.000 | 150.000 | 120 | 0,10 € | 0,40 € |
| Microsoft Azure | **OpenAI GPT-5.6 Sol Azure Sweden** | LLM | 500.000 | 250.000 | 500 | 4,50 € | 27,00 € |
| Microsoft Azure | **OpenAI GPT-5.6 Terra Azure Sweden** | LLM | 1.500.000 | 750.000 | 1.500 | 3,52 € | 15,82 € |
| Microsoft Azure | **OpenAI GPT-6.1 Sol Azure Sweden <=272k Input-Tokens** | LLM | 500.000 | 250.000 | 500 | 2,14 € | 10,68 € |
| Microsoft Azure | **OpenAI GPT-6.1 Sol Azure Sweden >272k Input-Tokens** | LLM | 500.000 | 250.000 | 500 | 4,28 € | 16,02 € |
| Microsoft Azure | **OpenAI GPT-6 Luna Azure Sweden <=272k Input-Tokens** | LLM | 500.000 | 250.000 | 500 | 0,11 € | 0,54 € |
| Microsoft Azure | **OpenAI GPT-6 Luna Azure Sweden >272k Input-Tokens** | LLM | 500.000 | 250.000 | 500 | 0,22 € | 0,81 € |
| Microsoft Azure | **OpenAI GPT-6 Astra Azure Sweden <=272k Input-Tokens** | LLM | 1.500.000 | 750.000 | 1.500 | 9,68 € | 48,40 € |

| Plattform | Modell | Modell-typ | Max. Input TPM | Max. Output TPM | Max. RPM | Preis pro Million Input-Token | Preis pro Million Output-Token |
|---|---|---|---|---|---|---|---|
| Microsoft Azure | **OpenAI GPT-6 Astra Azure Sweden >272k Input-Tokens** | LLM | 1.500.000 | 750.000 | 1.500 | 19,36 € | 72,60 € |
| Microsoft Azure | **OpenAI GPT-Image-2 (Input Text, Output Image)** | LLM | | | 3 | 4,39 € | 26,33 € |
| Microsoft Azure | **OpenAI GPT-Image-2 (Input Image, Output Image)** | LLM | | | 3 | 7,03 € | 26,33 € |
| Microsoft Azure | **OpenAI Ada-Text, Azure France** | Em-bedding | 6.000.000 | 3.000.000 | 6.000 | 0,11 € | 0,11 € |
| Google Cloud Platform & Microsoft Azure | **Mistral AI Mistral Medium 3.5** | LLM | 240.000 | 120.000 | 180 | 1,29 € | 6,44 € |
| Google Cloud Platform & Microsoft Azure | **Anthropic Claude Opus 5.5** | LLM | 12.000.000 | 1.200.000 | 1.200 | 3,92 € | 19,58 € |
| Google Cloud Platform & Microsoft Azure | **Anthropic Claude Sonnet 5.5** | LLM | 11.250.000 | 1.125.000 | 1.125 | 2,97 € | 14,85 € |
| Google Cloud Platform & Microsoft Azure | **Anthropic Claude Haiku 5.5 <=100k Input-Tokens** | LLM | 13.500.000 | 1.350.000 | 1.200 | 0,10 € | 0,50 € |
| Google Cloud Platform & Microsoft Azure | **Anthropic Claude Haiku 5.5 >100k Input-Tokens** | LLM | 13.500.000 | 1.350.000 | 1.200 | 0,50 € | 2,48 € |
| Google Cloud Platform & Microsoft Azure | **Anthropic Claude Fable 5.1** | LLM | 1.800.000 | 180.000 | 1.800 | 9,90 € | 49,50 € |
| Google Cloud Platform | **Google Gemini 3 Flash** | LLM | DSQ | DSQ | DSQ | 0,45 € | 2,70 € |
| Google Cloud Platform | **Google Gemini 3.5 Flash** | LLM | DSQ | DSQ | DSQ | 1,49 € | 8,91 € |
| Google Cloud Platform | **Google Gemini 3.8 Flash** | LLM | DSQ | DSQ | DSQ | 0,74 € | 3,68 € |
| Google Cloud Platform | **Google Gemini 4 Argon** | LLM | DSQ | DSQ | DSQ | 3,96 € | 19,80 € |

### 7.2.3 Tarif Agentic

Der monatliche Mindestumsatz für Modelle im Tarif Agentic beträgt: 5.000 €

| Plattform | Modell | Modell-typ | Max. Input TPM | Max. Output TPM | Max. RPM | Preis pro Million Input-Token | Preis pro Million Output-Token |
|---|---|---|---|---|---|---|---|
| T-Cloud Public | **Jina AI jina-embeddings-v2-base-de** | Em-bedding | 2.000.000 | 1.000.000 | 1.000 | 0,05 € | 0,05 € |
| T-Cloud Public | **BAAI text-embedding-bge-m3** | Em-bedding | 2.000.000 | 1.000.000 | 1.000 | 0,05 € | 0,05 € |
| T-Cloud Public / Industrial AI Cloud | **Qwen3-Embedding-8B** | Em-bedding | 600.000 | | 1.200 | 0,10 € | 0,10 € |
| T-Cloud Public / Industrial AI Cloud | **Qwen3-Reranker-4B** | Reranker | 2.000.000 | | 800 | 0,05 € | 0,05 € |
| T-Cloud Public | **OpenAI Whisper Large v3** | STT | 218 | | 300 | 14,61 € | 14,61 € |
| T-Cloud Public | **OpenAI Whisper Large v3 Turbo** | STT | 345 | | 300 | 9,21 € | 9,21 € |
| T-Cloud Public / Industrial AI Cloud | **OpenAI GPT-OSS-120B** | LLM | 2.000.000 | 2.000.000 | 300 | 0,20 € | 0,65 € |
| T-Cloud Public / Industrial AI Cloud | **Gemma 4 31B**<br>**Mistral AI Mistral Small 4**<br>**NVIDIA Nemotron 3 Super** | LLM | 300.000 | 300.000 | 150 | 0,60 € | 1,20 € |
| T-Cloud Public | **Qwen3.6 35B** | LLM | 300.000 | 300.000 | 150 | 0,60 € | 1,20 € |
| T-Cloud Public / Industrial AI Cloud | **Qwen 3.8 27B** | LLM | 300.000 | 300.000 | 150 | 0,50 € | 2,50 € |
| T-Cloud Public / Industrial AI Cloud | **GLM 5.3** | LLM | 1.600.000 | 200.000 | 200 | 1,40 € | 4,40 € |
| T-Cloud Public / Industrial AI Cloud | **GLM 5.3 Flash** | LLM | 2.000.000 | 2.000.000 | 300 | 0,20 € | 0,60 € |
| T-Cloud Public / Industrial AI Cloud | **LightOnOCR-3-4B** | OCR | 200.000 | 75.000 | 60 | 0,20 € | 0,60 € |
| T-Cloud Public / Industrial AI Cloud | **PaddleOCR-VL-1.6** | OCR | 275.000 | 250.000 | 200 | 0,10 € | 0,40 € |
| Microsoft Azure | **OpenAI GPT-5.6 Sol Azure Sweden** | LLM | 1.000.000 | 500.000 | 1.000 | 4,50 € | 27,00 € |
| Microsoft Azure | **OpenAI GPT-5.6 Terra Azure Sweden** | LLM | 2.500.000 | 1.250.000 | 2.500 | 3,52 € | 15,82 € |
| Microsoft Azure | **OpenAI GPT-6.1 Sol Azure Sweden <=272k Input-Tokens** | LLM | 1.000.000 | 500.000 | 1.000 | 2,14 € | 10,68 € |
| Microsoft Azure | **OpenAI GPT-6.1 Sol Azure Sweden >272k Input-Tokens** | LLM | 1.000.000 | 500.000 | 1.000 | 4,28 € | 16,02 € |
| Microsoft Azure | **OpenAI GPT-6 Luna Azure Sweden <=272k Input-Tokens** | LLM | 1.000.000 | 500.000 | 1.000 | 0,11 € | 0,54 € |
| Microsoft Azure | **OpenAI GPT-6 Luna Azure Sweden >272k Input-Tokens** | LLM | 1.000.000 | 500.000 | 1.000 | 0,22 € | 0,81 € |
| Microsoft Azure | **OpenAI GPT-6 Astra Azure Sweden <=272k Input-Tokens** | LLM | 2.500.000 | 1.250.000 | 2.500 | 9,68 € | 48,40 € |

| Plattform | Modell | Modell-typ | Max. Input TPM | Max. Output TPM | Max. RPM | Preis pro Million Input-Token | Preis pro Million Output-Token |
|---|---|---|---|---|---|---|---|
| Microsoft Azure | **OpenAI GPT-6 Astra Azure Sweden >272k Input-Tokens** | LLM | 2.500.000 | 1.250.000 | 2.500 | 19,36 € | 72,60 € |
| Microsoft Azure | **OpenAI GPT-Image-2 (Input Text, Output Image)** | LLM | | | 5 | 4,39 € | 26,33 € |
| Microsoft Azure | **OpenAI GPT-Image-2 (Input Image, Output Image)** | LLM | | | 5 | 7,03 € | 26,33 € |
| Microsoft Azure | **OpenAI Ada-Text, Azure France** | Em-bedding | 10.000.000 | 5.000.000 | 10.000 | 0,11 € | 0,11 € |
| Google Cloud Platform & Microsoft Azure | **Mistral AI Mistral Medium 3.5** | LLM | 400.000 | 200.000 | 300 | 1,29 € | 6,44 € |
| Google Cloud Platform & Microsoft Azure | **Anthropic Claude Opus 5.5** | LLM | 20.000.000 | 2.000.000 | 2.000 | 3,92 € | 19,58 € |
| Google Cloud Platform & Microsoft Azure | **Anthropic Claude Sonnet 5.5** | LLM | 18.750.000 | 1.875.000 | 1.875 | 2,97 € | 14,85 € |
| Google Cloud Platform & Microsoft Azure | **Anthropic Claude Haiku 5.5 <=100k Input-Tokens** | LLM | 22.500.000 | 2.250.000 | 2.000 | 0,10 € | 0,50 € |
| Google Cloud Platform & Microsoft Azure | **Anthropic Claude Haiku 5.5 >100k Input-Tokens** | LLM | 22.500.000 | 2.250.000 | 2.000 | 0,50 € | 2,48 € |
| Google Cloud Platform & Microsoft Azure | **Anthropic Claude Fable 5.1** | LLM | 3.000.000 | 300.000 | 3.000 | 9,90 € | 49,50 € |
| Google Cloud Platform | **Google Gemini 3 Flash** | LLM | DSQ | DSQ | DSQ | 0,45 € | 2,70 € |
| Google Cloud Platform | **Google Gemini 3.5 Flash** | LLM | DSQ | DSQ | DSQ | 1,49 € | 8,91 € |
| Google Cloud Platform | **Google Gemini 3.8 Flash** | LLM | DSQ | DSQ | DSQ | 0,74 € | 3,68 € |
| Google Cloud Platform | **Google Gemini 4 Argon** | LLM | DSQ | DSQ | DSQ | 3,96 € | 19,80 € |

### 7.2.4 Preise für optionale Dienstleistungen

Der Tagessatz für optionale Dienstleistungen wie Implementierungssupport, Beratung und Coaching beträgt 1.144,45 €.

Die Leistungen werden remote erbracht. Die Abrechnung der Unterstützungsleistungen erfolgt monatlich anhand eines vom Auftraggeber unterzeichneten Leistungsnachweises auf Basis von Time&Material.

# 8 Glossar/ Abkürzungsverzeichnis

| Abkürzung | Erklärung |
|---|---|
| **API-Key** | Ein API-Key ist ein einzigartiger Authentifizierungsschlüssel, der den Zugriff auf eine Programmierschnittstelle (API) ermöglicht, indem er die aufrufende Anwendung identifiziert, authentifiziert und autorisiert. |
| **ASR** | Automatic Speech Recognition, Automatische Spracherkennung |
| **Betreute Betriebszeit** | Ist die Zeit von Montag bis Freitag jeweils von 9:00 Uhr bis 17:00 Uhr MEZ/MESZ, ausgenommen an bundeseinheitlichen Feiertagen in Deutschland |
| **DSQ** | Dynamic Shared Quota |
| **LLM** | Large Language Model |
| **Modelle** | Modelle umfassen in diesem Dokument Large Language Modelle, Embedding-Modelle, Reranker-Modelle, OCR-Modelle und Speech-to-Text-Modelle |
| **OCR** | Optical Character Recognition, Optische Zeichenerkennung |
| **PaaS** | Platform as a Service |
| **SaaS** | Software as a Service |
| **Token** | Token umfassen Input- als auch Output-Token, sofern nicht differenziert wird.<br>Token sind Textsequenzen, z. B. Sätze, Wörter oder Zeichen, die ein LLM verarbeiten kann. Die Größe eines Tokens kann sich je nach LLM unterscheiden. |
| **TPM** | Die Anzahl der maximal verarbeitbaren Tokens pro Minute |
| **RPM** | Die Anzahl der maximal verarbeitbaren Requests pro Minute |